Soft Actor-Critic no Hopper-v5

Igor Garbin Manzan Mazo e Christian de Souza Ramos | Atividade SAC | 20/10/2026

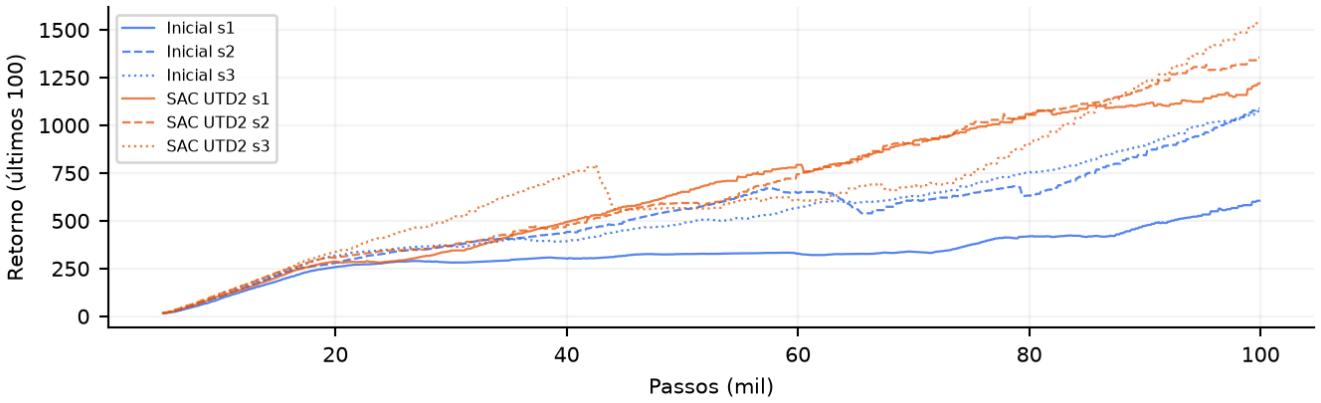
Código e configurações no fork | Projeto W&B e runs

Validação. Reparametrização com rsample(), correção do jacobiano do tanh e alvo soft implementados. Os 16 testes SAC passaram. Pendulum: retorno determinístico -132,9 em 10 episódios (limiar: -200). Apenas os dois blocos do SAC foram alterados; train.py recebeu uma correção na impressão das taxas.

Parte 3 - Eficiência amostral. Cada configuração SAC usou exatamente 100.000 passos e seeds 1, 2 e 3. Valores: média (mínimo a máximo). Os intervalos são amplitudes entre seeds, não intervalos de confiança.

Mudança / motivo observado	Avaliação	Últimos 100	Veredito
Inicial (CleanRL)	1770.7 (1718.7 a 1851.4)	921.4 (604.6 a 1086.8)	Referência
sac.learning_starts: 5000 -> 1000 No run t36lm0u3, em 9201 passos, retorno last100=74.28: testar aprendizado mais cedo para aproveitar o orçamento curto.	1631.9 (673.1 a 3256.3)	963.1 (589.4 a 1296.9)	indistinguível do ruído
sac.q_lr: 0.001 -> 0.0003 No run t36lm0u3, alpha caiu de 1 para 0.121 em 9201 passos; q_lr controla também a temperatura: testar adaptação mais lenta.	1553.3 (332.2 a 2829.1)	646.2 (317.7 a 823.7)	indistinguível do ruído
sac.updates_per_step: 1 -> 2 No run 26ut4s0r, em 8101 passos, retorno last100=65.57: testar maior reutilização das transições por passo de ambiente.	2854.9 (2625.2 a 3218.2)	1372.2 (1219.5 a 1541.5)	melhora

O candidato updates_per_step=2 foi selecionado: até seu pior seed (2.625,2) superou o melhor inicial (1.851,4). Seu retorno de treino também não se sobrepõe ao inicial. Antecipar o aprendizado e reduzir q_lr produziram amplitudes grandes; não há evidência de melhora robusta nesses candidatos. O critério conservador de não sobreposição foi registrado antes da seleção.

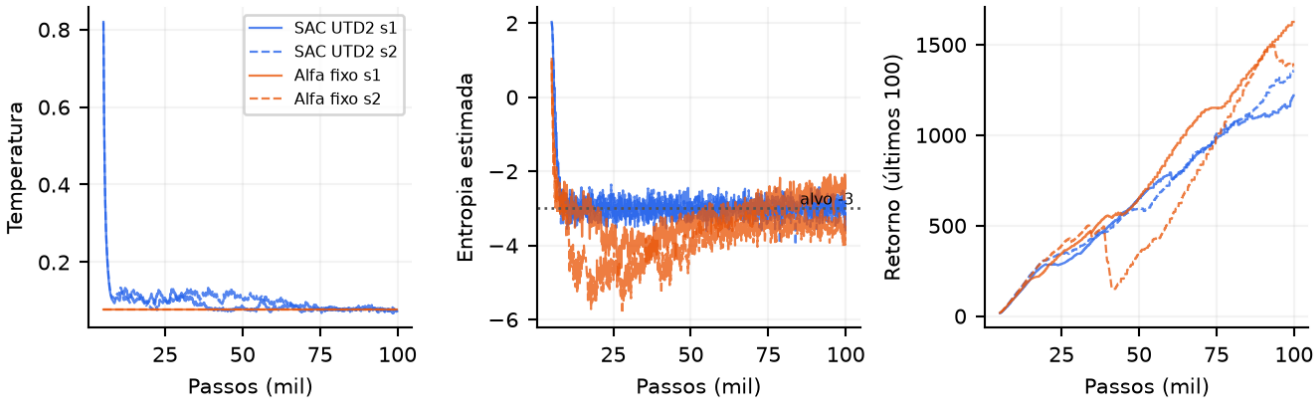


Curvas sem suavização. Inicial: t36lm0u3 (s1), 26ut4s0r (s2), 29hhhoxn (s3). Comparação: ehumli2v (s1), s5x1j5ij (s2), a6kc83xb (s3).

Parte 4 - Temperatura fixa

Previsão registrada antes do treino. Com alfa fixo 0.0771, escolhido no regime final da referência, espero menos regularização inicial do que no autotune, que começa em 1. Isso pode acelerar a adoção de ações já valorizadas, mas reduzir a diversidade e aumentar a variação entre seeds. A entropia pode se afastar do alvo -3 porque não há realimentação ajustando a temperatura; não prevejo melhora robusta de retorno.

Escolha do alfa. Alfa fixo 0.0771: mediana das medianas de losses/alpha dos três seeds entre 80.000 e 100.000 passos, arredondada a três algarismos significativos. As medianas por seed foram 0,0790, 0,0771 e 0,0656.



Referência: ehumli2v (s1), s5x1j5ij (s2). Alfa fixo: vt1sx3kl (s1), fy0tak74 (s2).

Resultado e mecanismo. A previsão se confirmou parcialmente: a avaliação com alfa fixo variou de 1.214,5 a 3.190,2, contra 2.625,2 a 2.721,2 na referência (mesmos seeds 1 e 2); não houve melhora consistente na avaliação. Já o retorno de treino final foi maior nos dois seeds: 1.380,4 e 1.625,4, contra 1.219,5 e 1.355,5. Portanto, a maior variabilidade prevista aparece na avaliação, mas não autoriza dizer que a ablação simplesmente piorou toda a aprendizagem.

Avaliação determinística: referência 2673.2 (2625.2 a 2721.2) (seeds 1 e 2); alfa fixo 2202.3 (1214.5 a 3190.2) (2 seeds). As curvas sobrepõem apenas seeds 1 e 2 de cada configuração.

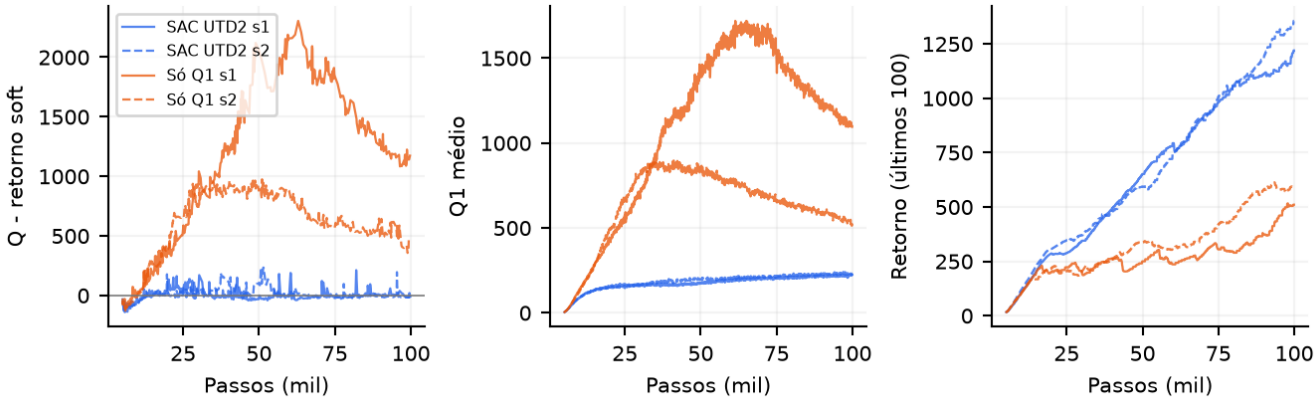
Leitura conjunta. Entre 80 e 100 mil passos, as medianas de entropia foram -2,60 e -3,44 com alfa fixo, contra -2,98 e -2,97 com autotune. O valor fixo escolhido no fim do treino não reproduz a trajetória da temperatura desde o início, e não corrige desvios em relação ao alvo. Alfa constante, entropias divergentes e avaliações distintas sustentam essa leitura conjunta; um retorno de treino maior não garantiu uma política média melhor nos dois seeds.

A entropia de uma densidade contínua pode ser negativa. Aqui, o alvo -3 corresponde às três dimensões da ação; a comparação usa a log-probabilidade corrigida pelo tanh.

Referência técnica: algorithms/sac.py:341 inicia a temperatura; 489-497 ajustam log_alpha apenas quando autotune=true; 179 e 483 ligam a temperatura ao alvo soft e à perda do ator. A amostra reparametrizada está na linha 147 e a correção do tanh na 150.

Parte 4 - Um crítico no alvo e ator

Previsão registrada antes do treino. Ao usar apenas Q1 no alvo e na perda do ator, espero maior superestimação: Q - retorno soft tende a ficar mais positivo e Q1 pode crescer sem ganho proporcional no retorno. Espero maior instabilidade entre seeds e possível piora na avaliação, pois o ator pode explorar erros otimistas do crítico.



Referência: ehumli2v (s1), s5x1j5ij (s2). Q1: qmtddnag (s1), eao35iz1 (s2).

Resultado e mecanismo. A previsão se confirmou nestes runs: entre 80 e 100 mil passos, a mediana de Q - retorno soft foi +1.260,1 e +529,6 usando Q1, contra +5,6 e -6,9 na referência. As medianas de Q1 também subiram para 1.230,4 e 592,8 (referência: 214,8 e 226,8), enquanto os retornos de treino finais caíram para 510,3 e 592,1. As avaliações ficaram em 524,0 e 2.101,9, ambas abaixo das referências de mesmo seed; a amplitude também aumentou. Assim, valores Q maiores refletiram otimismo sem ganho de retorno: retirar o mínimo permite que o alvo e o ator aproveitem erros positivos de Q1.

Nesta implementação, clipped_double_q=false substitui o mínimo por Q1 no alvo e no ator. Q2 continua sendo calculado e treinado; a ablação testa o uso do mínimo, não a economia computacional de remover uma rede.

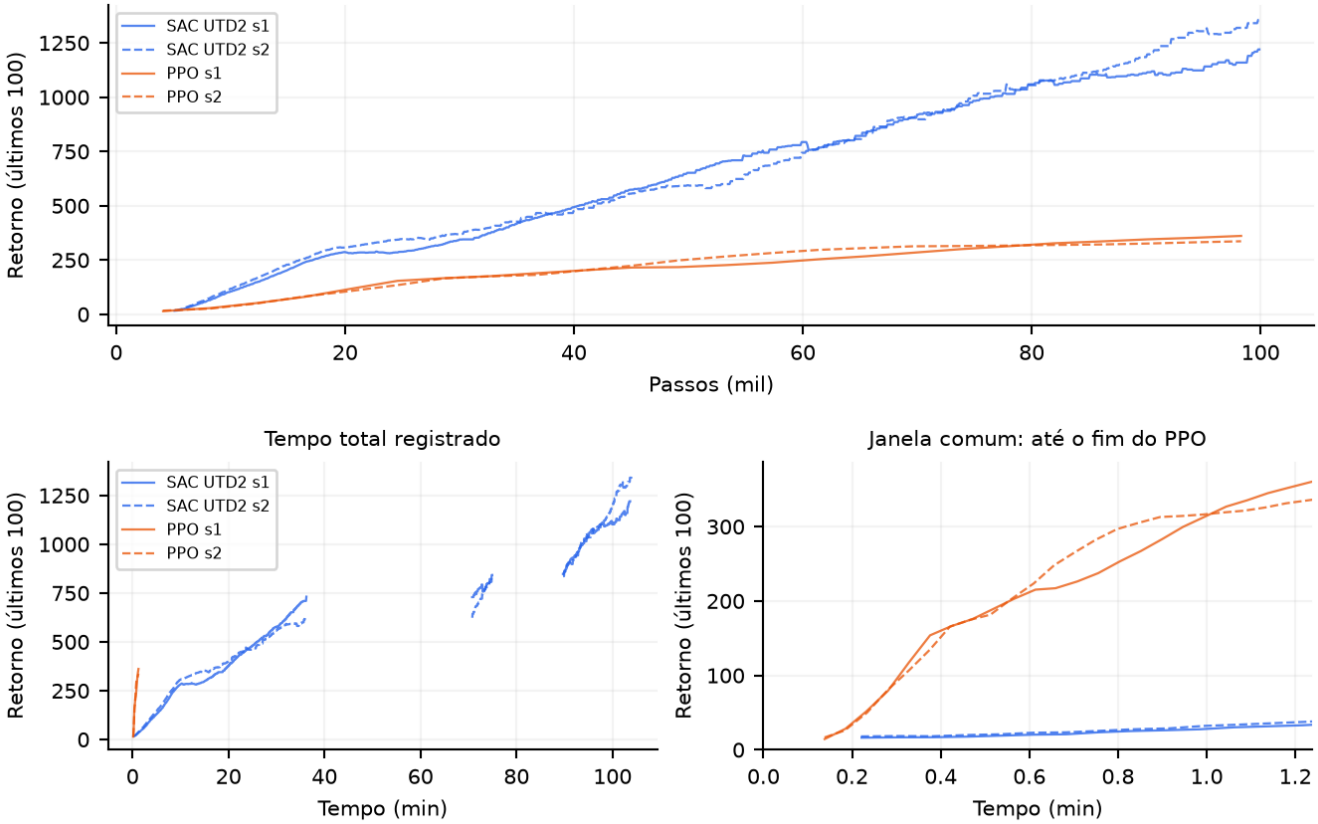
Avaliação determinística: configuração com Q1 1313.0 (524.0 a 2101.9). Os valores Q incluem desconto e entropia; não devem ser comparados diretamente com o retorno bruto.

Referência técnica: algorithms/sac.py:367 seleciona Q1 quando clipped_double_q=false; 455-458 aplicam essa escolha ao alvo e 483 à perda do ator. O mínimo do alvo está na linha 179.

Limites da interpretação. O diagnóstico Q - retorno usa um episódio observado, cuja política e temperatura podem mudar durante a coleta. No limite temporal, também ignora o bootstrap após a truncagem. No Hopper, gamma elevado a 1.000 é aproximadamente 0,000043. Dois seeds descrevem estes runs, mas não sustentam uma afirmação universal sobre a ablação.

Parte 5 - SAC versus PPO

Previsão. Espero que o SAC alcance maior retorno por passo, pois reutiliza o replay muitas vezes e aprende uma política estocástica por gradientes através das ações. Espero que o PPO processe mais passos por segundo, pois intercala rollouts longos com otimização em lotes; com updates_per_step=2 o SAC tende a custar ainda mais tempo. A diferença de retorno entre seeds pode impedir uma conclusão robusta.



SAC: ehumli2v (s1), s5x1j5ij (s2). PPO: 8sebon73 (s1), o0y9tw5p (s2). Tempo: campo _runtime do W&B, em minutos; inclui a inicialização. Há duas lacunas de cerca de 34,5 e 14,7 min nos runs SAC; as linhas são interrompidas nas lacunas. O painel direito amplia a janela comum antes delas.

A previsão se confirmou nestes runs: ao final, o SAC teve retorno de treino 1.287,5 (1.219,5-1.355,5), contra 348,4 (336,0-360,8) do PPO. Até cerca de 74 s, porém, o SAC estava em 6.401 passos e retorno 32,8-37,6, enquanto o PPO já estava perto de terminar. Nesse trecho, SPS era 95-96 no SAC contra aproximadamente 1.440 no PPO. O tempo total do SAC inclui duas grandes lacunas e não mede custo isolado de execução.

A avaliação final original do PPO amostra ações. Para comparar desempenho ao longo do treino, as figuras usam a mesma métrica de retorno episódico nos dois algoritmos.

Reutilização das amostras. No último registro, SAC fez 189.800 atualizações Q: 189.800 x 256 / aproximadamente 99.300 transições armazenadas = cerca de 489 participações em minibatches por transição; amostras antigas tendem a aparecer mais. O ator também reutiliza esses estados, com duas atualizações a cada duas atualizações Q (sac.py:479-480). PPO fez 7.680 atualizações: 10 épocas por rollout, portanto 10 usos por transição. Dobrar updates_per_step dobra a intensidade de reutilização e aumenta o custo por passo. Replay (sac.py:448), bônus de entropia (179), mínimo dos críticos (179/483) e gradiente através da ação (147) ajudam a explicar o ganho amostral; os contadores Q e PPO não representam operações idênticas.

Orçamento efetivo. O comando do enunciado configura 100.000 passos nos dois algoritmos. O PPO original fecha 24 rollouts de 4.096 transições: 98.304 passos, 1,696% abaixo do teto. O código PPO e seus hiperparâmetros foram preservados. O SAC conclui os 100.000 passos.

Limite causal. Replay, entropia, dois críticos e ator reparametrizado são mecanismos plausíveis, mas SAC e PPO também diferem nas redes e na normalização; a comparação não isola cada causa.