PPO: resultado e protocolo experimental

Resultado: o PPO final atendeu aos dois critérios de retorno em ambas as seeds.

Implementamos GAE, a perda clipada com log-probabilidades antigas e vantagens constantes, e os diagnósticos sem gradiente. Os 34 testes de PPO/A2C passaram. A rede e as funções de A2C são as da atividade anterior; a busca alterou somente configurações de treino, sem modificar a dinâmica dos algoritmos.

Seeds 1 e 2; LunarLander-v3; MLPs separados de duas camadas de 64 unidades Tanh. PyTorch 2.9.1 CPU, Gymnasium 1.2.0 e Box2D 2.3.8, Windows. Avaliação final: dez episódios, política estocástica, conforme o executor do curso. A configuração inicial usa 1 milhão de passos; PPO final e A2C usam 2 milhões nominais (1.998.848 e 1.999.872 efetivos, respectivamente; diferença de arredondamento de 1.024 passos).

Tabela 1. Resultados ao final de cada treino.

Configuração / seed	Run W&B	Retorno últimos 100	Avaliação final
Inicial / 1	9lejwwgc	-20,9	29,8
Inicial / 2	it98mxjn	26,5	20,4
PPO / 1	bcmc5d1x	272,1	274,3
PPO / 2	iur5byix	257,6	263,3
A2C / 1	fr4d0uq8	-51,4	-34,9
A2C / 2	pt52h35c	-93,5	-72,6

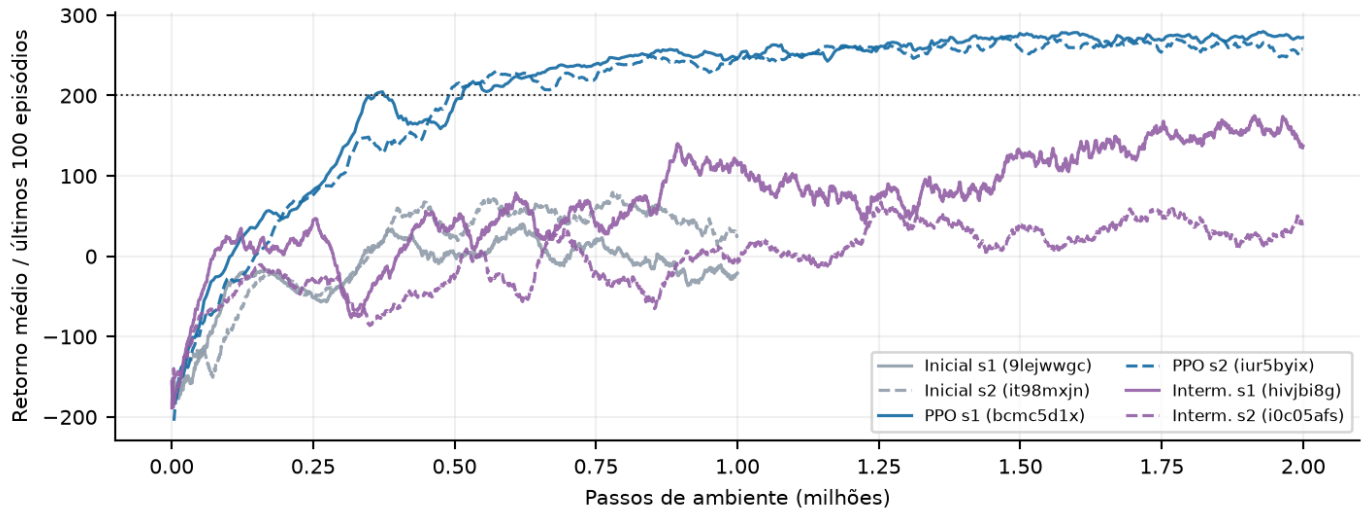


Figura 1. Retorno inicial, intermediário e final, duas seeds cada. Linhas tracejadas: seed 2; pontilhado horizontal: meta 200. Cada legenda identifica o run.

A configuração inicial não resolveu o ambiente: avaliações de 29,8 e 20,4. Esse resultado e seus diagnósticos motivaram os ajustes da página seguinte.

Ajustes orientados pelos diagnósticos

Chave	Inicial	Final
total_timesteps	1000000	2000000
ppo.num_steps	128	1024
ppo.gamma	0.99	0.999
ppo.gae_lambda	0.95	0.98
ppo.num_minibatches	4	16
ppo.update_epochs	4	10
ppo.clip_vloss	True	False
ppo.ent_coef	0.01	0.001

Primeiro ajuste (Figura 2). Nos runs iniciais 9lejwwgc e it98mxjn, a média dos últimos 100 registros de KL ficou próxima de 0,00001 e clipfrac foi zero; a taxa de aprendizado estava chegando a zero. A variância explicada ficou em 0,63 e 0,56. Testamos mais reuso (4 para 10 épocas), desativação do clipping da perda do crítico e maior orçamento, permitindo mais treino antes do fim do decaimento.

Segundo ajuste (Figuras 1 e 2). Em hivjbi8g, o retorno caiu de cerca de 136 para 74; i0c05afs ficou perto de zero após 1 milhão. Entropias de 0,59/0,72 motivaram reduzir ent_coef. Rollouts de 128 para 1.024 e minibatches de 4 para 16 (nominalmente 128 para 256 amostras/minibatch) testam atualizações menos ruidosas. Gamma e lambda maiores ampliam o alcance dos retornos diante do progresso instável. Essas são hipóteses motivadas pelas curvas, não causas já demonstradas.

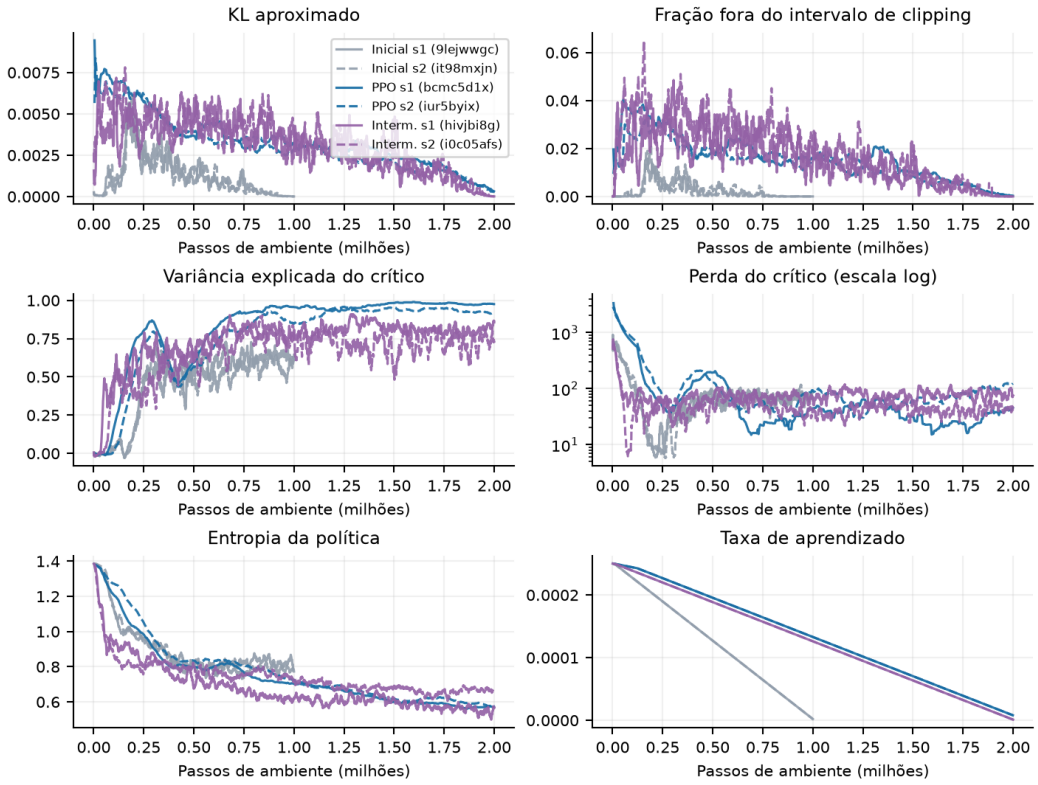


Figura 2. Inicial, intermediário e final (runs nas legendas); média móvel de 30 registros. Clipfrac mede razões fora do intervalo, não necessariamente gradientes efetivamente anulados.

O que ocorreu depois. No PPO final, a variância explicada média nos últimos 100 registros foi 0,98 e 0,93; entropias de 0,58 e 0,60. As curvas estabilizaram acima de 200 (Figura 1); o KL volta a cair com o decaimento da taxa.

Intermediário, treino/avaliação: hivjbi8g: 137,2/183,1; i0c05afs: 33,9/73,7. As alterações foram conjuntas: a comparação não isola a contribuição causal de cada uma.

PPO versus A2C: amostras e tempo

A2C partiu de a2c_cartpole, com LunarLander-v3, o mesmo orçamento de 2 milhões e num_steps=32 em vez de 5. O retorno mais longo busca representar melhor consequências do pouso; os demais hiperparâmetros foram preservados. É uma tentativa de comparação, sem exigência de resolver o ambiente com A2C.

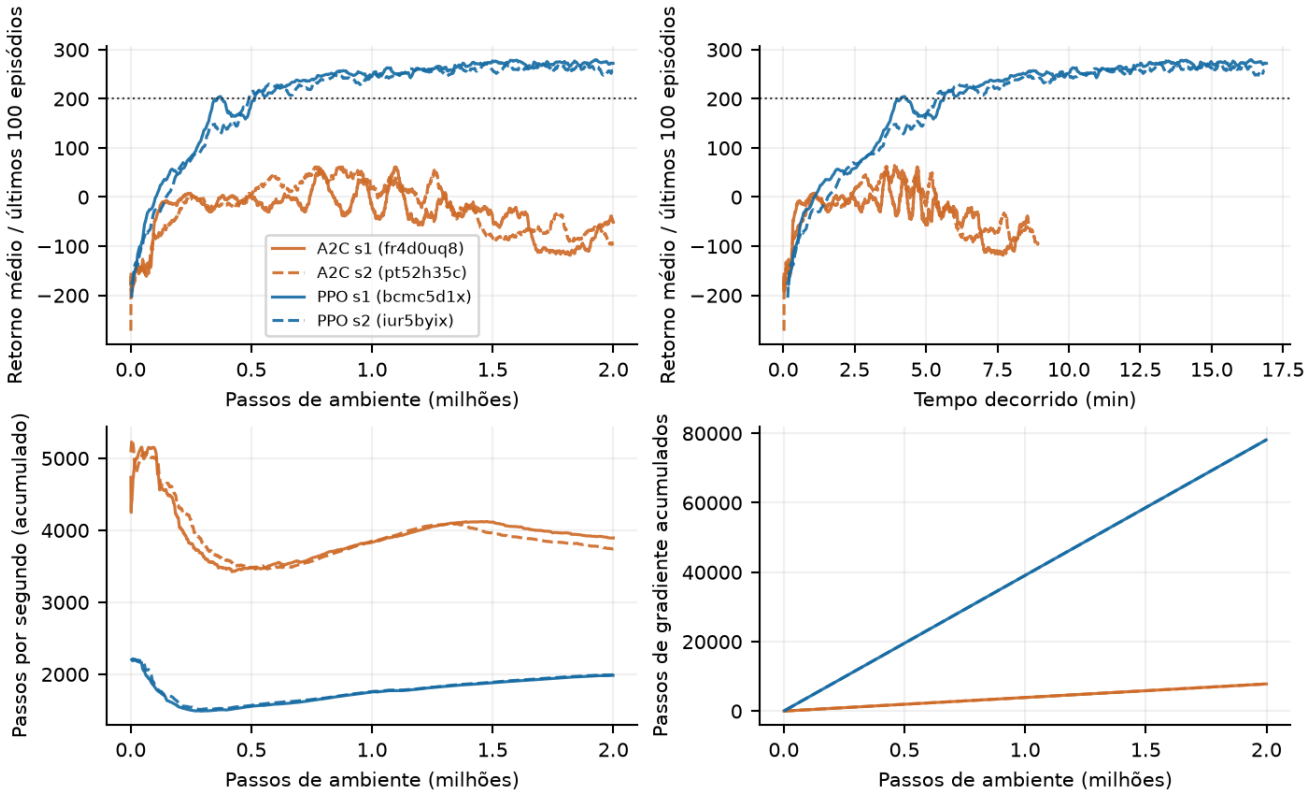


Figura 3. Mesmas seeds e orçamento: retorno × passos, retorno × tempo, SPS e número acumulado de passos de gradiente. Tempo contado após a inicialização do W&B; avaliação e upload ficam fora das curvas.

Run	Passos até 0	Até 100	Até 200	Tempo / SPS
PPO s1	106.496	274.432	360.448	16,9 min / 1984
PPO s2	147.456	299.008	491.520	16,9 min / 1992
A2C s1	217.344	não atingiu	não atingiu	8,6 min / 3893
A2C s2	252.672	não atingiu	não atingiu	8,9 min / 3742

Os limiares usam a primeira média dos últimos 100 episódios registrada acima do valor; não significam permanência. No orçamento final, PPO executou 78.080 atualizações por seed, contra 7.812 no A2C. O reuso de minibatches aumenta o custo de otimização por passo de ambiente e ajuda a explicar o menor SPS do PPO.

Com o mesmo tempo observado de 8,6 minutos, a média entre seeds foi 250,8 para PPO e -56,2 para A2C. Essa leitura usa o último registro de cada run disponível até esse instante. Execução concorrente e comprimentos de episódio diferentes limitam a generalização dos tempos.

Estabilidade, mecanismos e rastreabilidade

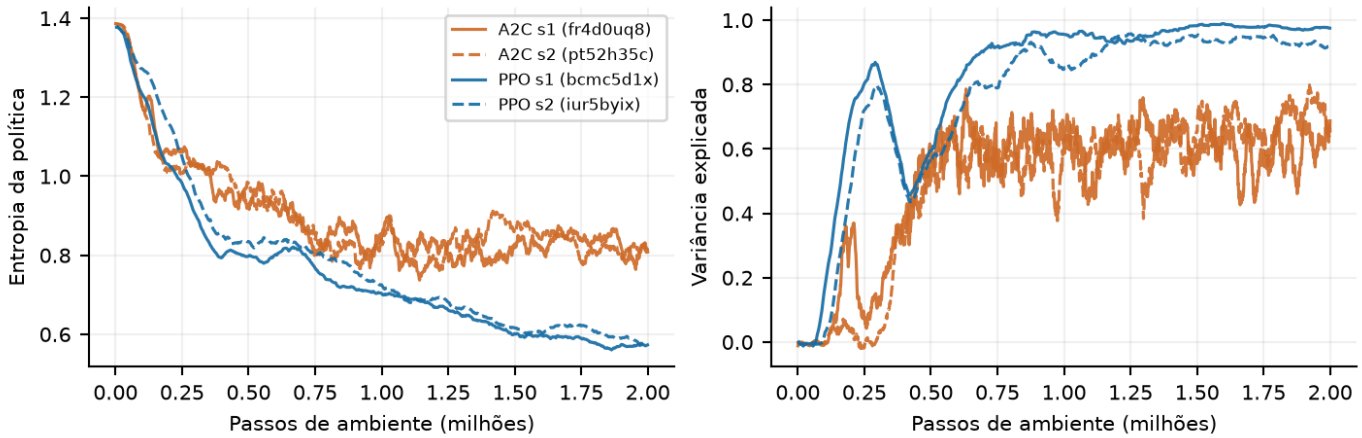


Figura 4. Entropia e variância explicada de PPO e A2C, com os runs identificados; média móvel de 30 registros. Interpretar junto do retorno na Figura 3.

Estabilidade. A diferença final entre seeds foi 14,5 pontos no PPO e 42,1 no A2C. A maior queda entre um pico anterior e um registro posterior foi 46,0 / 23,2 no PPO e 179,8 / 160,7 no A2C (seeds 1 / 2). São estatísticas descritivas das curvas de treino, não intervalos de confiança; duas seeds não bastam para afirmar superioridade universal.

GAE. Combina resíduos temporais com fator gamma * lambda, enquanto o A2C usa um único retorno de n passos. As curvas do crítico (Figura 4) são compatíveis com diferenças na qualidade dos alvos e vantagens, mas também dependem do ajuste de valor e do número de atualizações. Não há uma ablação que isole GAE.

Reuso de amostras. A Figura 3 mostra diretamente o maior número de atualizações por amostra no PPO. Isso permite extrair mais aprendizado de cada rollout, com custo de tempo adicional. A curva de retorno por passos é a medida de eficiência amostral; SPS sozinho não mede qualidade.

Razão de probabilidades. Corrige o objetivo para a política que coletou o rollout, necessária quando os mesmos dados são reutilizados após atualizações. O KL da Figura 2 mede esse afastamento; não há uma razão equivalente no único update on-policy de A2C.

Clipping. Limita o incentivo do objetivo a mudanças excessivas na direção favorável à vantagem. A clipfrac da Figura 2 quantifica quantas razões saem do intervalo; não garante um limite rígido de KL nem ausência de quedas de retorno. Seu papel deve ser interpretado junto do reuso e da correção por razões.

Código e evidências. Fork: IgorGMMazo/t-zero-learning, branch codex/ppo-assignment. Implementação, configs, scripts de análise e dados em reports/ppo. Projeto W&B: ppo-assignment.

Runs: Inicial s1: 9lejwwgc; Inicial s2: it98mxjn; PPO s1: bcmc5d1x; PPO s2: iur5byix; A2C s1: fr4d0uq8; A2C s2: pt52h35c.